



# 自动驾驶中多传感器信息融合理论

Camera + LiDAR + Radar + IMU



购买该课程请扫描二维码

主 讲 人：爱喝苦咖啡的小阿飞

公 众 号：3D 视 觉 工 坊

# 内容

一、信息融合的概述

二、信息融合的基本原理

四、传感器同步理论补充内容



自动驾驶传感器融合主要是将同方向不同传感器探测的目标在统一的坐标系下设计一定的融合算法进行智能化合成，产生更精确、鲁棒的目标属性信息。这种系统可以消除不同传感器之间目标的冗余和矛盾问题，增加传感器之间数据的**互补性**，提高传感器数据的使用效率，保证自动驾驶感知系统的**实时性和可靠性**。





相比于单一的传感器，多传感器融合有以下特点：

- a. **冗余性**：多个传感器数据对目标的描述表示是相同的（如激光雷达检测的目标信息和摄像头目标信息大体一致，允许有一定的属性误差）；
- b. **互补性**：由于每个传感器的探测范围和探测属性不同，传感器之间的目标属性可以相互补充（如前方障碍物的颜色信息，激光雷达识别不出来）；
- c. **合作性**：不同传感器在处理信息时会对其他信息有所依赖（如相机在建立位姿关系时，需要依赖IMU的数据）；
- d. **信息分层**：可以根据数据融合所呈现的位置，进行分层，包括原始数据层（简称像元层）、特征层、决策层（也叫目标层），这种信息分层有助于根据需求设计不同的算法，同时进行并行处理机制，保证系统的实时性；



多传感器信息融合，简单说，就是利用计算机技术将多传感器的信息数据，在一定准则下进行分析和综合，以完成所需的决策和估计而进行的信息处理过程，具体来讲，多传感器融合步骤如下：

- ◆ 多个不同类型传感器收集观测目标的数据；
- ◆ 对传感器的输出数据进行特征处理，或数据关联；
- ◆ 利用融合算法对特征或关联数据进行分析 and 处理，最终得到目标一致性判断。

上面的第三步步骤有些牵强，后面会依据具体的融合算法进行详细的步骤解读。

在多传感器融合中，按照对原始数据处理方法的不同，多传感器融合系统的体系结构可以分为三种：集中式，分布式和混合式(混合式又分为有反馈结构和无反馈结构)。







传统方法：姜还是老的辣！！！！

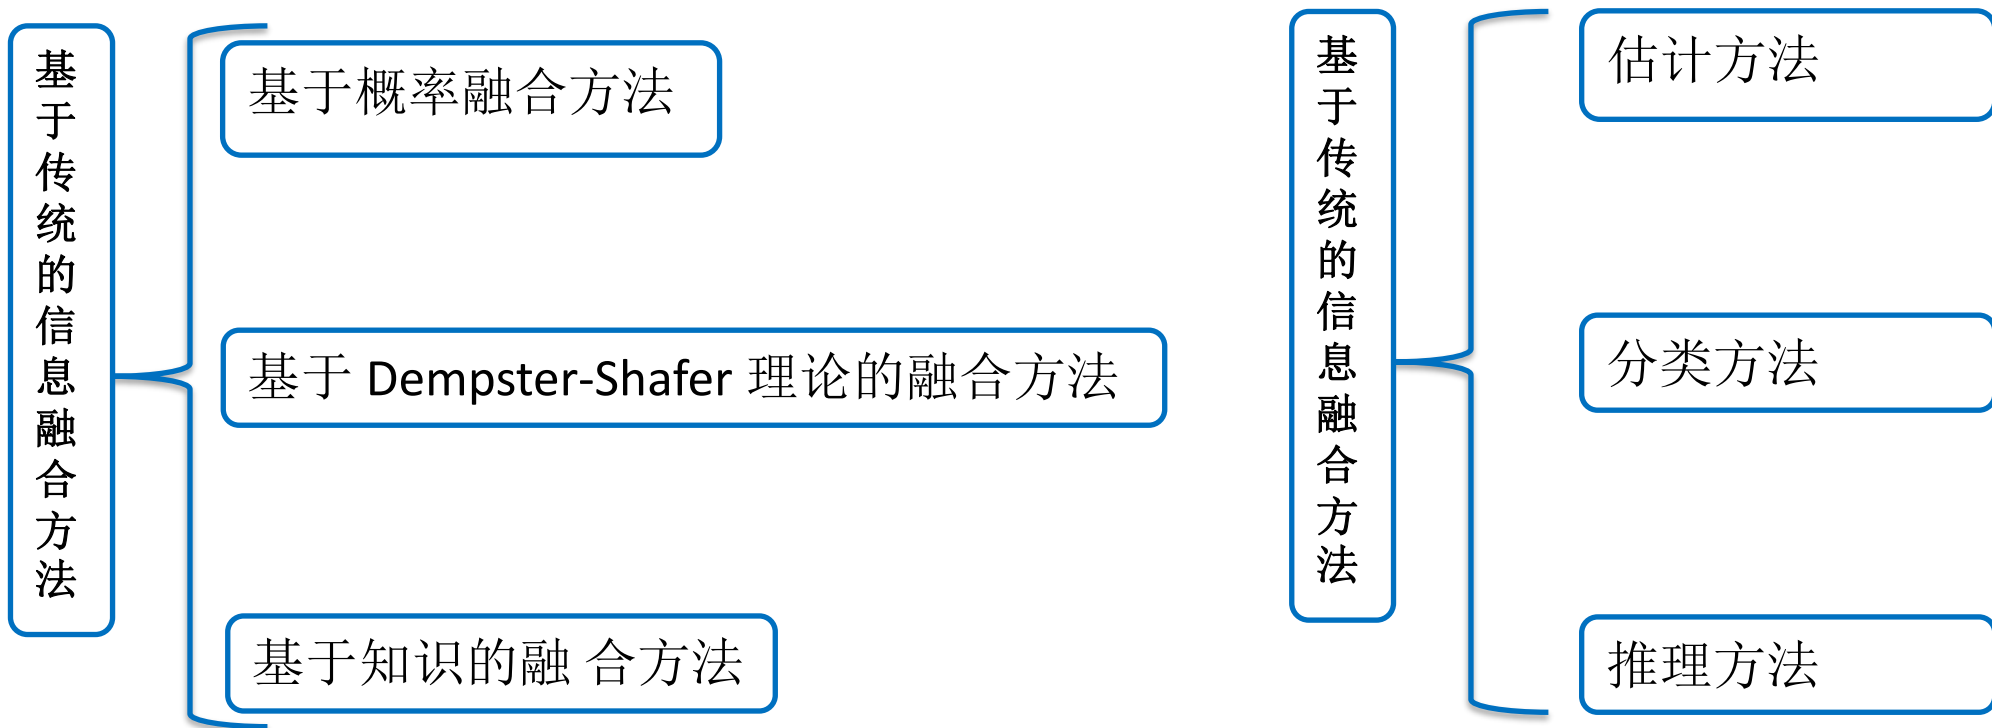


深度学习方法：年轻就是干！！！！





### 基于传统的信息融合方法



基于传统方法的信息融合分类



### 基于传统的信息融合方法

#### 估计方法之加权平均法

**加权平均**是最简单直接、也是最实用的方法，就是将来自各个传感器的目标结果进行匹配处理后，按照每个传感器所占的权值进行加权平均，加权平均后的结果作为融合的结果。这种方法比较适用于动态环境中，但需要对传感器结果和性能进行详细的分析，以获得准确的权值。

$$result = a * SensorA + b * SensorB + c * SensorC + \dots, a+b+c+\dots = 1$$






### 基于传统的信息融合方法

#### 估计方法之最小二乘法

**最小二乘法**就是将不同传感器的目标观测值进行近似拟合，使得拟合函数针对不同传感器的目标观测值的误差的平方和最小。



一般不单一使用最小二乘法，而是将其与其他融合方法一起使用，或者来校验其他融合方法的好坏。原因如下：

假设左图中的红点为**多个传感器观测得到的物理量**，那么这些物理量之间看似存在某种函数关系，所以，需要用最小二乘法来拟合这些点，并比较各函数针对各点的误差平方和最小，从而得到最终的系数。那么得到的曲线就是融合后的轨迹点。当然，如果将上图中的红点看作是某个融合函数融合后得到的结果，那么与蓝线之间的误差平方和最小，也可以用来评价原融合方法的好坏。



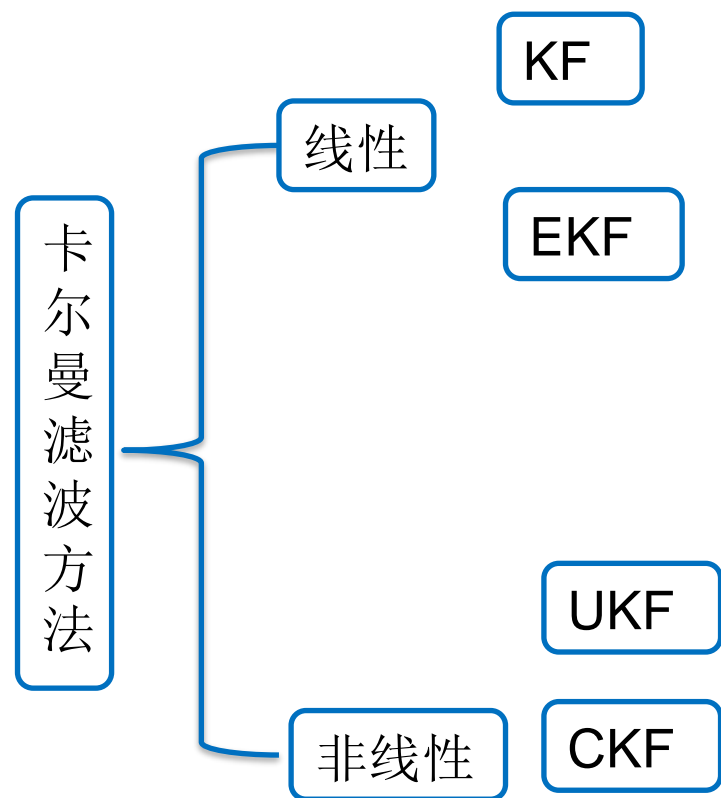
### 基于传统的信息融合方法

#### 估计方法之卡尔曼滤波及其变种

卡尔曼滤波主要用于融合低层次实时动态多传感器冗余数据。该方法用测量模型的统计特性递推，决定统计意义下的最优融合和数据估计。如果系统具有线性动力学模型，且系统与传感器的误差符合高斯白噪声模型，则卡尔曼滤波将为融合数据提供唯一统计意义下的最优估计。

卡尔曼滤波的递推特性使系统处理无需大量的数据存储和计算。但是采用单一的卡尔曼滤波器对多传感器组合系统进行数据统计时，存在很多严重问题，例如：

- ① 在组合信息大量冗余情况下，计算量将以滤波器维数的三次方剧增，实时性难以满足。
- ② 传感器子系统的增加使故障概率增加，在某一系统出现故障而没有被检测出时，故障会污染整个系统，使可靠性降低。





### 基于传统的信息融合方法

#### 分类方法之聚类分析

**一致度：**讨论一致度的目的是为聚类提供基础。通过聚类分析，可以把一致性高的数据进行融合，对于“不一致”的个别数据可能认为是在恶劣环境下偶然造成的“奇异点”。如果在聚类分析中发现出现了多个距离分布较远的类，则说明整体数据具有高度的不一致性，这些数据反映了不同的系统特性，不能进行简单的融合。一致度是一种势函数 $K(X,Y)$ ，它需要满足几个条件：

1) 函数的输出为0~1之间，当两点X,Y距离很近时输出值大，当两点距离很远时输出值小；2) 函数的主体趋势时逐步下降的；3) 当X,Y两点重合时(距离为0),输出最大为1，当两点距离无穷大时，输出最大为0；4)  $K(X,Y)=K(Y,X)$ , 为连续函数。

**聚类分析：**在得到各个传感器数据的一致度后，很容易根据一致度来进行数据点的聚类，即把相似的点构成一个个集合。从一致度的公式可知，距离小于阈值的点一致度大，距离大的点其一致度小。

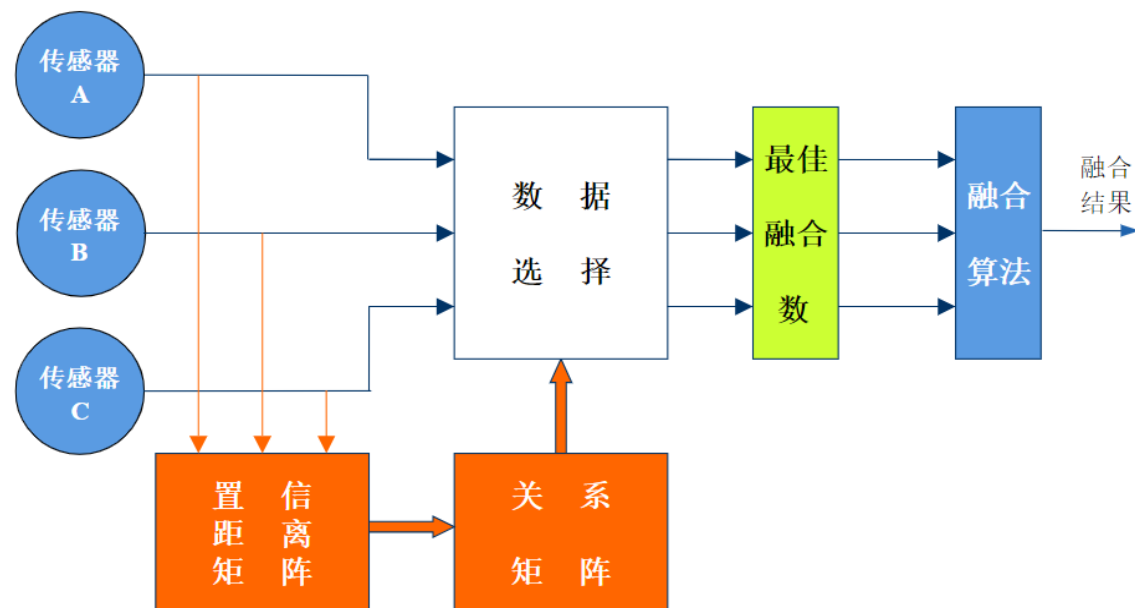


### 基于传统的信息融合方法

#### 推理方法之贝叶斯方法

贝叶斯方法就是将每一个传感器作为一个贝叶斯估计，把各单独物体的关联概率分布合成一个联合的后验概率分布函数，通过使联合分布函数的似然函数为最小，提供多传感器信息的最终融合值，融合信息与环境的一个先验模型以提供整个环境的一个特征描述。

多贝叶斯估计是把每个传感器作为一个贝叶斯估计，将各单独物体的关联概率分布组合成一个联合后验概率分布函数，通过使联合分布函数的似然函数最小，可以得到多传感器信息的最终融合值。





### 基于传统的信息融合方法

#### 推理方法之D-S方法

该方法是贝叶斯推理的扩充，包含3个基本要点：基本概率赋值函数、信任函数和似然函数。D-S方法的推理结构是自上而下的，分为三级：

**第一级**为目标合成，首先对来自多个传感器的数据信息进行预处理，计算各个证据的基本概率分布函数，可信度，释然度；

**第二级**为推断，根据DS合成规则，计算所有争取联合作用下的基本概率分配函数、可信度、释然度；

**第三级**为更新，各传感器一般都存在随机误差，因此在时间上充分独立地来自同一传感器的一组连续报告(报告就是处理后的概率分布函数，可信度，释然度等)比任何单一报告更加可靠。所以在推理和多传感器合成之前，要先组合（更新）传感器的观测数据。



### 基于深度学习方法的信息融合方法

基于深度学习的信息融合方法

基于深度学习特征提取的数据融合方法

基于深度学习全过程的数据融合方法

基于深度学习融合的数据融合方法

基于深度方法的图像点云融合

基于原始数据的图像点云融合方法

基于结果的图像点云融合方法

基于中间层特征的图像点云融合方法

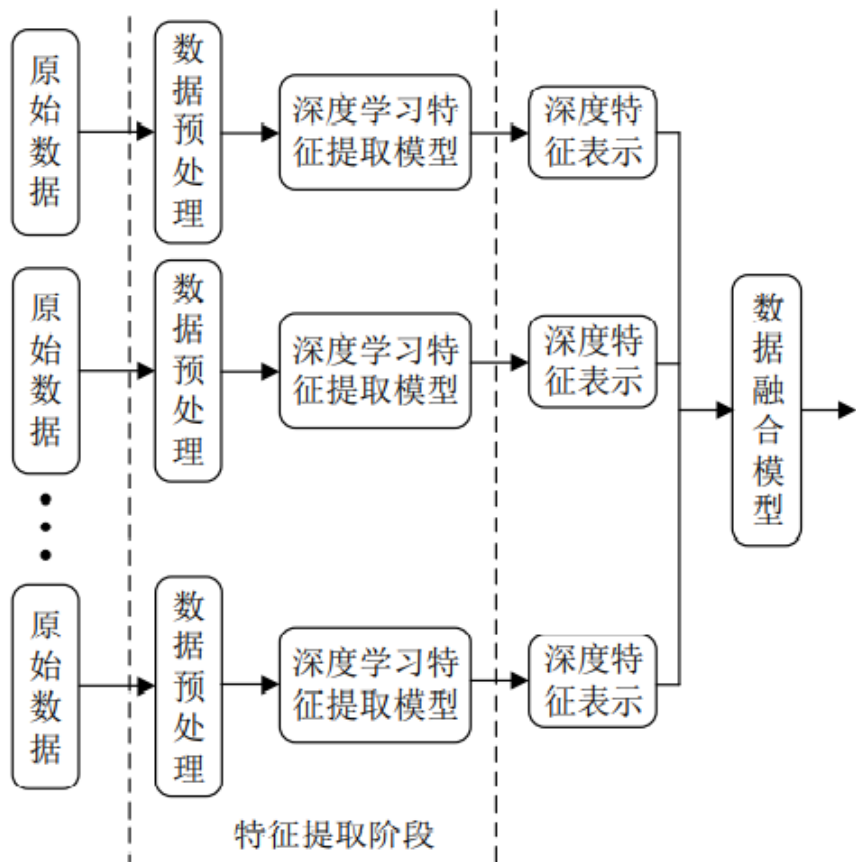
基于深度学习方法的信息融合分类



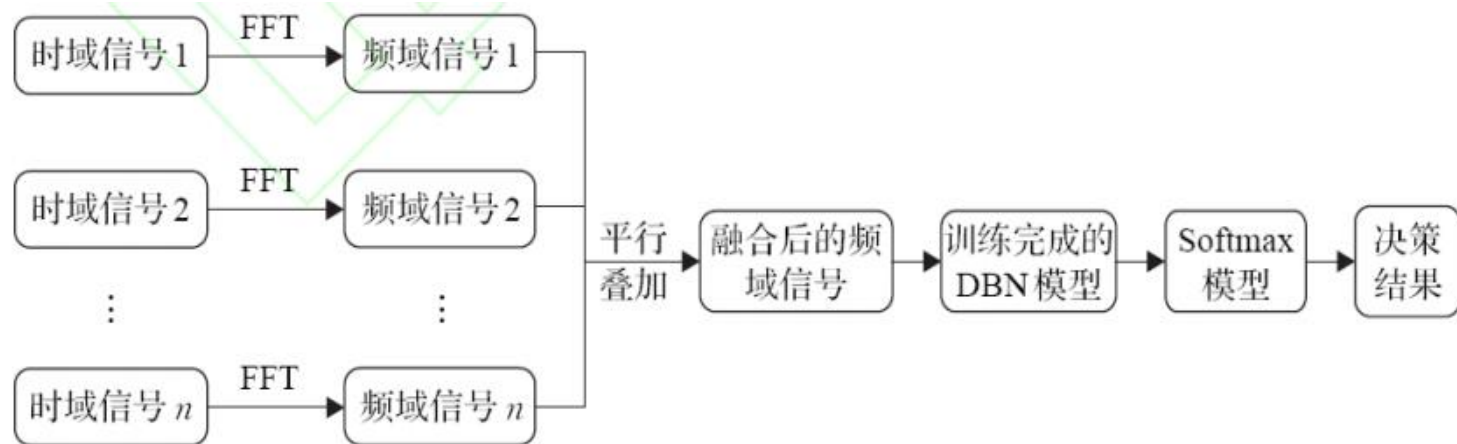


### 基于深度学习方法的信息融合方法

#### 基于深度学习特征提取的数据融合方法



基于深度学习特征提取的数据融合模型

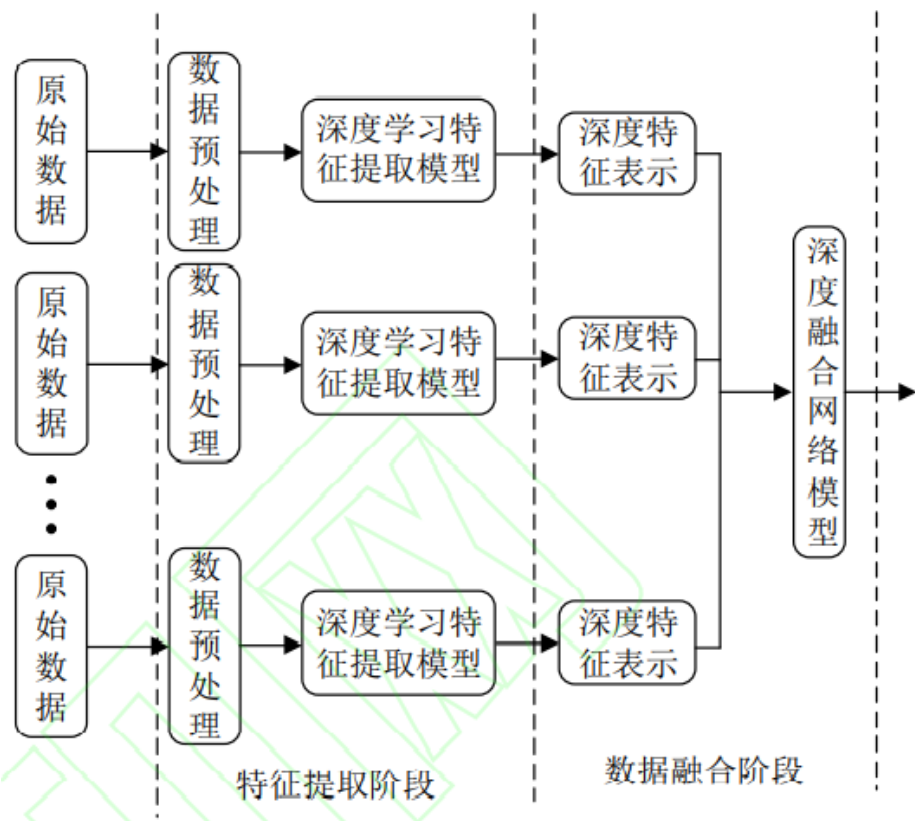


基于DBN的多传感器数据融合模型

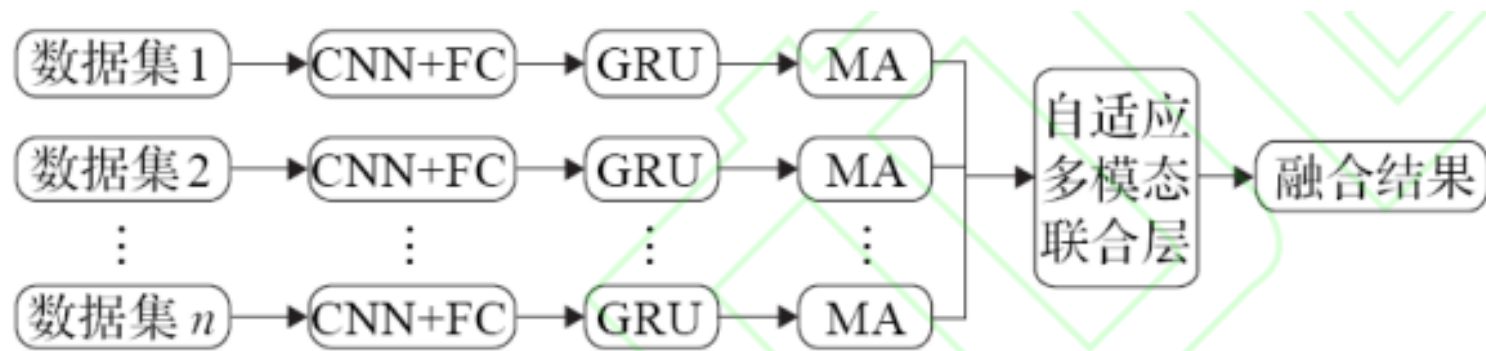


### 基于深度学习方法的信息融合方法

#### 基于深度学习全过程的数据融合方法



基于深度学习全过程的数据融合模型

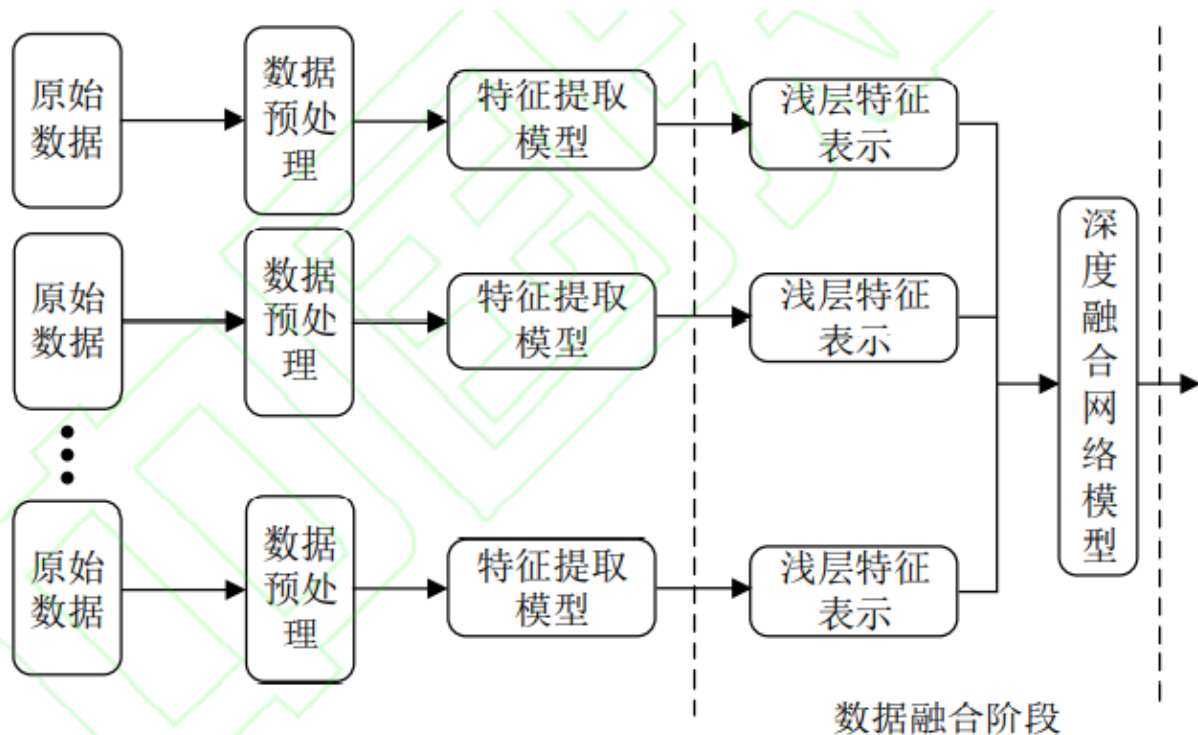


基于CNN, GRU和自适应多模态联合数据融合模型

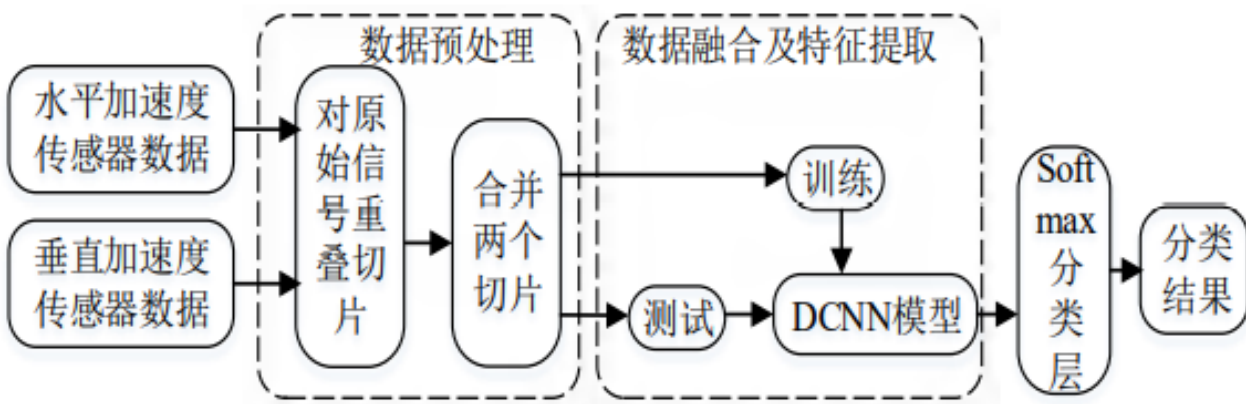


### 基于深度学习方法的信息融合方法

#### 基于深度学习融合的数据融合方法



基于深度学习融合的数据融合模型



基于深度卷积神经网络的数据融合模型



表 2 常用的数据融合方法与基于深度学习数据融合方法比较

Table 2 Comparison of common data fusion methods and data fusion methods based on deep learning


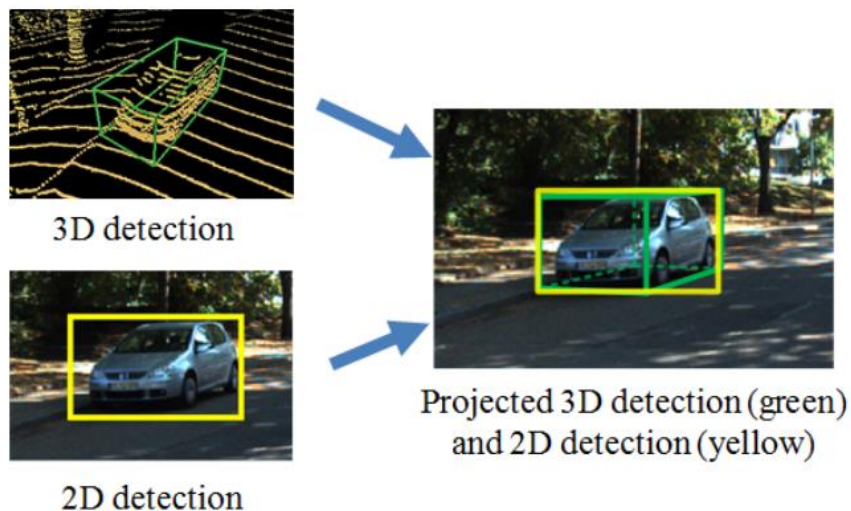
融合方法	处理数据量	复杂度	特征提取方式	实时性	资源消耗	融合质量
传统数据融合方法	少量数据	低	人工标注等	好	低	相对较差
基于深度学习数据融合方法	海量数据	高	自动特征提取	差	高	相对较好

传统的数据融合方法和基于深度学习的数据融合方法在应用场景、融合思路等方面存在差异：


- ◆ 传统的数据融合方法在对数据进行特征提取时，通常采用专家制定提取规则或人工标注等方式进行，因此适合处理小规模数据集。但是人工提取特征会导致提取的特征不全面，无法进一步挖掘多源数据间存在的关联关系，使得决策精度降低。
- ◆ 在实时性方面，传统数据融合方法复杂度相对较低，具有更好的实时性。
- ◆ 基于深度学习的数据融合方法具有自学习能力和非线性特点，能够自动挖掘数据的相关特征，因此在对海量数据进行融合时具有优势。但是基于深度学习的数据融合方法的复杂度较高，训练模型较为费时并且对计算设备的计算能力要求较高。



### 基于深度学习方法的图像与点云融合方法



### 基于原始数据的图像点云融合方法(Only Fusion)



### 基于中间特征层的图像点云融合方法(Deep Fusion)

### 基于结果的图像点云融合方法(Late Fusion)


[https://blog.csdn.net/weixin\\_40805392](https://blog.csdn.net/weixin_40805392)





### 对毫米波雷达进行标定的方法、装置及系统

本说明书实施例公开了一种对毫米波雷达进行标定的方法、装置及系统,所述方法包括获取激光雷达特征点数据,所述激光雷达特征点数据根据激光雷达所在车辆沿预设轨迹移动时所述激光雷达对目标物进行信息采集获得;获取毫米波雷达数据,所述毫米波雷达数据根据所述车辆沿预设轨迹移动时所述毫米波雷达对所述目标物进行信息采集获得;利用初始标定矩阵将所述毫米波雷达数据投影至激光雷达坐标系中,获得激光雷达坐标系下的毫米波雷达数据;根据所述激光雷达特征点数据以及激光雷达坐标系下的毫米波雷达数据确定所述毫米波雷达的标定矩阵,以利用所述标定矩阵对所述毫米波雷达进行标定。利用本说明书各个实施例,可以实现对毫米波雷达数据的准确融合。



获取激光雷达特征点数据,所述激光雷达特征点数据根据激光雷达所在车辆沿预设轨迹移动时所述激光雷达对目标物进行信息采集获得

获取毫米波雷达数据,所述毫米波雷达数据根据所述车辆沿预设轨迹移动时所述毫米波雷达对所述目标物进行信息采集获得

利用初始标定矩阵将所述毫米波雷达数据投影至激光雷达坐标系中,获得激光雷达坐标系下的毫米波雷达数据,所述初始标定矩阵根据所述毫米波雷达及激光雷达在所述车辆上的物理相对位置确定

根据所述激光雷达特征点数据以及激光雷达坐标系下的毫米波雷达数据确定所述毫米波雷达的标定矩阵,以利用所述标定矩阵对所述毫米波雷达进行标定





### 运动补偿方法

### 之融合方法

#### Odom与匹配方法的结合

- 用里程计方法进行矫正，去除绝大部分的运动畸变；
- 认为里程计存在误差，但是误差值是线性分布的；
- 用ICP的方法进行匹配，匹配的结果作为真值，得到里程计的误差值；
- 把误差值均摊在每一个点上，重新进行激光点位置修正；
- 再一次进行ICP迭代，直到收敛为止；

### 位置误差的线性假设比位置线性假设更合理！！！！

如下图所示，采用了激光雷达里程计和ICP方法进行运动补偿，绿色部分为原始的点云数据，粉色为去除运动畸变的点云数据，很明显前半部分粉色的点云数据超前绿色的点云数据，后半部分的点云数据近乎重合。局部放大发现，粉色的点云数据超前于绿色的点云数据，但是形状依旧类似，怀疑与没有IMU数据校准相关。这个例子是为了位置误差比位置的线性假设更合理，IMU数据没有进行校准，才导致以下结果。

目的是为了说明位置误差的线性假设比位置线性假设更合理。如图，左侧图像是整体点云利用激光里程计和ICP去除运动畸变的效果，激光雷达从左向右运动。点云的右半部分绿色点和粉色点基本重合了，但右半部分局部放大发现，粉色的点云数据超前于绿色的点云数据，但是形状依旧类似，怀疑与没有IMU数据校准相关（IMU的标定手册中有个**bias**，就好像相机内参的信息，这里IMU数据没校准指的是IMU没有考虑**bias**，就是没有考虑偏差，偏差可以理解成误差，而从图上看，右半部分确实整体偏移了一个数值）。





[\[1\] 基于聚类的多传感器数据融合方法研究](#)

[2] PointPainting: Sequential Fusion for 3D Object Detection

[3] Sensor Fusion for Joint 3D Object Detection and Semantic Segmentation

[4] Deep Continuous Fusion for Multi-Sensor 3D Object Detection

[5] Joint 3D Proposal Generation and Object Detection from View



购买该课程请扫描二维码



咨询课程请扫描二维码



**感谢聆听**

Thanks for Listening